

随机矩阵理论的研究（一）：元素独立随机方阵

朱梦

初稿于 2025-06-12, 修改于 2025-06-14

1. 奇异值与奇异向量

（一）奇异值分解（SVD）。对于任意矩阵 $A \in \mathbb{C}^{m \times n}$, 可分解为:

$$A = U \Sigma V^* \quad (1)$$

其中, $U \in \mathbb{C}^{m \times m}$ 表示左奇异向量组成的正交矩阵, 对应 AA^* 的特征向量, $\Sigma \in \mathbb{R}^{m \times n}$ 表示对角矩阵, 对角线元素为奇异值 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ (r 为矩阵的秩), $V \in \mathbb{C}^{n \times n}$ 表示右奇异向量组成的正交矩阵, 对应 A^*A 的特征向量。

（二）奇异值的性质。（1）非负性: $\sigma_i \geq 0$ 。（2）降序排列: $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ 。

（三）奇异向量的性质。（1）正交归一性: U 的列向量两两正交且模长为 1, V 的列向量两两正交且模长为 1。（2）方向性: 左奇异向量指向数据的主成分方向, 右奇异向量指向原始特征的主方向。

（四）几何解释。SVD 将矩阵变换分解为旋转 (V^T)、缩放 (Σ) 和再旋转 (U) 三个步骤。奇异值越大, 对应方向的“拉伸”效果越显著。

2. 特征值与特征向量

（一）特征值与特征向量的定义。对于方阵 $A \in \mathbb{C}^{n \times n}$, 若存在标量 $\lambda \in \mathbb{C}$ 和非零向量 $x \in \mathbb{C}^n$, 使得:

$$Ax = \lambda x \quad (2)$$

则称: λ 为 A 的特征值, x 为 A 的对应于 λ 的特征向量。

（二）特征值的代数性质。（1）特征值之和等于矩阵的迹（对角线元素之和）。特征值之积等于矩阵的行列式。（2）不同特征值对应的特征向量线性无关。重根特征值可能对应线性相关特征向量。（3）实对称矩阵的特征值为实数, 且不同特征值对应的特征向量正交。

（三）特征值的几何行为。当 λ 为实数，矩阵 \mathbf{A} 在特征向量方向上的变换为纯拉伸或压缩，无旋转成分。当 λ 为纯虚数，矩阵 \mathbf{A} 在特征向量方向上的变换为纯旋转，无拉伸或压缩。当 λ 为复数，矩阵 \mathbf{A} 在特征向量方向上的变换结合了拉伸/压缩与旋转。

3. 谱范数与谱半径

谱范数为矩阵的一种诱导范数，定义为矩阵的最大奇异值：

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^* \mathbf{A})} \quad (3)$$

其中， $\sigma_{\max}(\mathbf{A})$ 表示矩阵 \mathbf{A} 的最大奇异值， $\sqrt{\lambda_{\max}(\mathbf{A}^* \mathbf{A})}$ 表示矩阵 $\mathbf{A}^* \mathbf{A}$ 的最大特征值。对于线性变换 $\mathbf{A}\mathbf{x}$ ，谱范数 $\|\mathbf{A}\|_2$ 表示向量 \mathbf{x} 在变换后可能被拉伸的最大倍数，即 $\|\mathbf{A}\mathbf{x}\|_2 \leq \|\mathbf{A}\|_2 \|\mathbf{x}\|_2$ 。

谱半径是矩阵所有特征值的模的最大值：

$$\rho(\mathbf{A}) = \max_i |\lambda_i| \quad (4)$$

其中， λ_i 表示是矩阵 \mathbf{A} 的特征值。

对于任意复数矩阵 \mathbf{A} ，都有：

$$\rho(\mathbf{A}) \leq \|\mathbf{A}\|_2 \quad (5)$$

当且仅当矩阵 \mathbf{A} 为正规矩阵（即 $\mathbf{A}^* \mathbf{A} = \mathbf{A} \mathbf{A}^*$ ）时，谱半径等于谱范数：

4. 独立元素随机方阵

对于一个随机方阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ ，其元素独立重复采样于均值为 0，方差为 $1/n$ 的随机分布（随机分布可以是正太分布、均匀分布或截断正太分布）。当 n 很大时，其特征值分布服从圆律（Circular Law），即当 n 很大时，特征值在复平面上均匀分布在以原点为中心、半径为 1 的圆盘内：

$$|\lambda_i| \leq 1, \lambda_i \in \mathbb{C} \quad (6)$$

$$f_{\text{pdf}}(\lambda_i) = \begin{cases} \frac{1}{\pi}, & \text{如果 } |\lambda_i| \leq 1, \\ 0, & \text{其它} \end{cases} \quad (7)$$

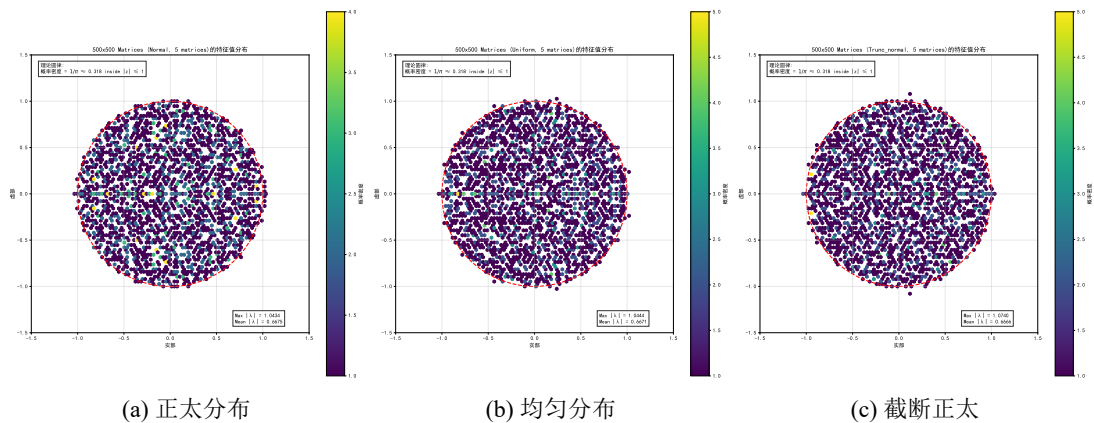


图 1 从不同随机分布采样所得方阵的特征值分布

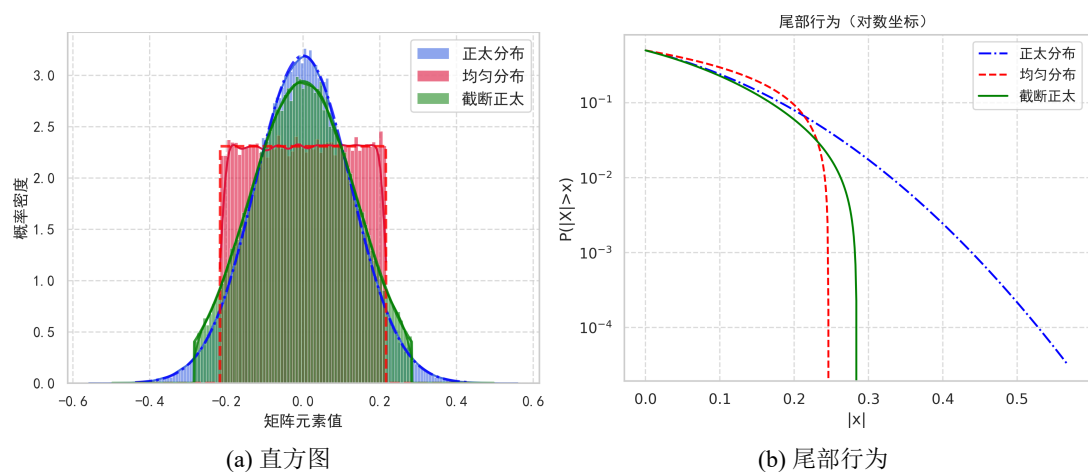


图 2 从三类随机分布采样所得方阵的元素分析及其比较

为什么高维下会有随机向量“近似正交归一化”的直觉？不妨设 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$

的分量都是从均值为 0，方差为 $1/n$ 的随机分布中独立重复采样出来的，那么有：

$$\begin{aligned} \langle \mathbf{u}, \mathbf{v} \rangle &= \left(n \times \frac{1}{n} \right) \sum_{i=1}^d u_i v_i \\ &\approx n \times \mathbb{E}_{u_i \sim f_{\text{PDF}}(x), v_i \sim f_{\text{PDF}}(x)}[u_i v_i] \\ &= n \times \mathbb{E}_{u_i \sim f_{\text{PDF}}(x)}[u_i] \times \mathbb{E}_{v_i \sim f_{\text{PDF}}(x)}[v_i] \\ &= 0 \end{aligned} \tag{8}$$

$$\begin{aligned} \langle \mathbf{u}, \mathbf{u} \rangle &= \left(n \times \frac{1}{n} \right) \sum_{i=1}^n u_i^2 \\ &\approx n \times \mathbb{E}_{u_i \sim f_{\text{PDF}}(x)}[u_i^2] \\ &= n \times (\mu^2 + \sigma^2) \\ &= 1 \end{aligned} \tag{9}$$

因此，对任意固定向量 \mathbf{x} ，有： $\|\mathbf{Ax}\|_2 \approx \|\mathbf{x}\|_2$ （等距近似），但这不改变方阵 \mathbf{A} 的特征值在复平面内部的分布！

表 1 从三类随机分布采样所得到方阵的比较

随机分布类型	特征值分布	与正交矩阵的近似程度
正太分布	精确圆律（解析可证）	近似最低（元素无界）
均匀分布	渐近圆律（普适性原理）	近似中等（元素有界）
截断正太	渐近圆律（普适性原理）	近似最高（元素有界且接近正太）

```
1 import numpy as np
2 from scipy.stats import norm, uniform, truncnorm
3
4 # 设置参数
5 n = 500 # 矩阵维度
6 var = 1 / n
7 sigma = (1 / n) ** 0.5
8 np.random.seed(42)
9 x = np.random.normal(1, size=n)
10 I = np.eye(n)
11
12
13 def print_stats(name, data):
14     print(f"\n{name}分布统计:")
15     print(f"均值: {np.mean(data):.6f} (理论: 0.0)")
```

```

16     print(f"方差: {np.var(data):.6f} (目标: {var:.6f})")
17
18     '''数字验证Theta是否近似正交矩阵
19     '''
20     M = np.einsum("ik, kj->ij", data.T, data)
21     err = np.sqrt(np.mean(np.square(M - I)))
22     print(f"与正交矩阵的近似程度 (越小越好): {err:.6f} ")
23
24     '''数字验证等距近似
25     '''
26     z = np.einsum("ij,j->i", data, x)
27     x_norm = np.sqrt(np.mean(np.square(x)))
28     z_norm = np.sqrt(np.mean(np.square(z)))
29     err = abs(z_norm - x_norm)
30     print(f"等距近似的程度 (越小越好): {err:.6f} ")
31
32
33     normal_matrix = norm.rvs(loc=0, scale=sigma, size=(n, n))
34
35     a = (3 / n) ** 0.5
36     uniform_matrix = uniform.rvs(loc=-a, scale=2 * a, size=(n, n))
37
38     t = 2 # 截断阈值 (标准差倍数)
39     larger_sigma = sigma * 1.1368472343385565
40     a, b = -t * larger_sigma, t * larger_sigma # 截断边界
41     trunc_normal_matrix = truncnorm.rvs((a - 0) / larger_sigma, (b - 0) / larger_sigma,
42                                         loc=0, scale=larger_sigma,
43                                         size=(n, n))
44
45     print_stats("正态", normal_matrix)
46     print_stats("均匀", uniform_matrix)
47     print_stats("截断正态", trunc_normal_matrix)

```

输出结果为:

```

1  正态分布统计:
2  均值: 0.000007 (理论: 0.0)
3  方差: 0.002001 (目标: 0.002000)
4  与正交矩阵的近似程度 (越小越好): 0.044737
5  等距近似的程度 (越小越好): 0.034251
6
7  均匀分布统计:
8  均值: 0.000042 (理论: 0.0)
9  方差: 0.001995 (目标: 0.002000)
10 与正交矩阵的近似程度 (越小越好): 0.044605
11等距近似的程度 (越小越好): 0.008731
12
13 截断正态分布统计:

```

14 均值: 0.000042 (理论: 0.0)
15 方差: 0.002000 (目标: 0.002000)
16 与正交矩阵的近似程度 (越小越好): 0.044687
17 等距近似的程度 (越小越好): 0.029288